

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ
РОССИЙСКОЙ ФЕДЕРАЦИИ

Федеральное государственное автономное образовательное учреждение
высшего образования

«ТЮМЕНСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ»

Лабораторная работа №8

«Деревья решений»

Выполнили студенты:
Титов Павел Сергеевич
Чупеев Андрей Дмитриевич

Тюмень-2023

Постановка задачи

Для решения задачи кредитного скоринга рассмотрите данные файла CreditSample.txt. В файле указаны данные 149 клиентов некоторого банка. Решение о выдаче кредита данным клиентам указано в последнем, целевом признаке.

Решение

```
[16]: import pandas as pd
      from sklearn.model_selection import train_test_split
      from sklearn.tree import DecisionTreeClassifier, export_graphviz
      from sklearn.metrics import accuracy_score, classification_report
      from sklearn.preprocessing import OneHotEncoder
```

1 Загрузка данных

```
[17]: df = pd.read_csv('CreditSample.txt', delimiter='\t')
      df.to_csv('CreditSample.csv', index=False, encoding='utf-8')
      df.head()
```

```
[17]:
```

	Код	№ Паспорта	ФИО	Адрес	Размер ссуды, руб	Срок ссуды, мес	\
0	1	0936-866096	1	1	10000	12	
1	2	8355-512943	1	1	14000	12	
2	3	8017-098471	1	1	25000	18	
3	4	2762-945535	1	1	64000	48	
4	5	0459-997701	1	1	3500	6	

	Цель ссуды	Среднемесячный доход, руб	\
0	Покупка товара	4500	
1	Оплата за образование	8500	
2	Оплата за образование	7000	
3	Покупка и ремонт недвижимости	7000	
4	Покупка товара	3000	

	Среднемесячный расход, руб	Основное направление расходов	...	\
0	3000	Покупка товаров длит. пользования	...	
1	3000	Покупка и ремонт недвижимости	...	
2	4000	Затраты на образование (в т.ч. детей)	...	
3	5000	Покупка товаров длит. пользования	...	
4	1500	Содержание/аренда недвижимости, а/т	...	

	Срок работы на данном предприятии, лет	Направление деятельности заемщика	\
0	6	Реклама и маркетинг	
1	10	Адм.-хоз. и транспортная службы	
2	8	Участие в основной деятельности	
3	9	Участие в основной деятельности	
4	7	Участие в основной деятельности	

	Срок работы на данном направлении, лет	Пол	Семейное положение	\
0	8	Жен	Да	
1	12	Жен	Нет	
2	8	Жен	Да	
3	11	Муж	Нет	
4	8	Муж	Да	

	Количество лет	Количество иждивенцев	\
0	41	3	
1	26	0	
2	32	3	
3	50	2	
4	30	0	

	Срок проживания в данной местности, лет	Обеспеченность займа	Давать кредит
0	24	ИСТИНА	ИСТИНА
1	20	ИСТИНА	ИСТИНА
2	13	ИСТИНА	ИСТИНА
3	22	ИСТИНА	ИСТИНА
4	14	ИСТИНА	ЛОЖЬ

[5 rows x 26 columns]

2 Решение проблемы категориальных признаков

```
[18]: df = df.drop(columns=['Код', '№ Паспорта', 'ФИО', 'Адрес', 'Название_
→организации'])
```

```
[19]: df['Пол'] = df['Пол'].map({'Жен': 0, 'Муж': 1})
df['Наличие недвижимости'] = df['Наличие недвижимости'].map({'Да': 1, 'Нет': 0})
df['Наличие автотранспорта'] = df['Наличие автотранспорта'].map({'Да': 1, 'Нет': 0})
df['Наличие банковского счета'] = df['Наличие банковского счета'].map({'Да': 1,
→'Нет': 0})
df['Наличие страховки'] = df['Наличие страховки'].map({'Да': 1, 'Нет': 0})
df['Семейное положение'] = df['Семейное положение'].map({'Да': 1, 'Нет': 0})
df['Обеспеченность займа'] = df['Обеспеченность займа'].map({'ИСТИНА': 1, 'ЛОЖЬ':
→ 0})
df['Давать кредит'] = df['Давать кредит'].map({'ИСТИНА': 1, 'ЛОЖЬ': 0})
```

```
[20]: df.head()
```

	Размер ссуды, руб	Срок ссуды, мес	Цель ссуды	\
0	10000	12	Покупка товара	
1	14000	12	Оплата за образование	
2	25000	18	Оплата за образование	

3	64000	48	Покупка и ремонт недвижимости
4	3500	6	Покупка товара

	Среднемесячный доход, руб	Среднемесячный расход, руб	\
0	4500	3000	
1	8500	3000	
2	7000	4000	
3	7000	5000	
4	3000	1500	

	Основное направление расходов	Наличие недвижимости	\
0	Покупка товаров длит. пользования	1	
1	Покупка и ремонт недвижимости	1	
2	Затраты на образование (в т.ч. детей)	1	
3	Покупка товаров длит. пользования	1	
4	Содержание/аренда недвижимости, а/т	0	

	Наличие автотранспорта	Наличие банковского счета	Наличие страховки	...	\
0	1	0	0	...	
1	1	0	0	...	
2	1	0	0	...	
3	1	0	0	...	
4	1	0	0	...	

	Срок работы на данном предприятии, лет	Направление деятельности заемщика	\
0	6	Реклама и маркетинг	
1	10	Адм.-хоз. и транспортная службы	
2	8	Участие в основной деятельности	
3	9	Участие в основной деятельности	
4	7	Участие в основной деятельности	

	Срок работы на данном направлении, лет	Пол	Семейное положение	\
0	8	0	1	
1	12	0	0	
2	8	0	1	
3	11	1	0	
4	8	1	1	

	Количество лет	Количество иждивенцев	\
0	41	3	
1	26	0	
2	32	3	
3	50	2	
4	30	0	

	Срок проживания в данной местности, лет	Обеспеченность займа	\
0	24	1	

1	20	1
2	13	1
3	22	1
4	14	1

Давать кредит	
0	1
1	1
2	1
3	1
4	0

[5 rows x 21 columns]

Решение проблем с нечисловыми категориальными признаками, используя OneHotEncoder

```
[21]: non_numeric_columns = df.select_dtypes(include=['object']).columns.tolist()

encoder = OneHotEncoder(sparse=False, handle_unknown='ignore')
encoded_columns = encoder.fit_transform(df[non_numeric_columns])

encoded_df = pd.DataFrame(encoded_columns, columns=encoder.
    ↪get_feature_names_out(non_numeric_columns))

df = df.drop(non_numeric_columns, axis=1)
df = pd.concat([df, encoded_df], axis=1)
```

```
/Users/zeto/Projects/university/5sem/mitmo/venv/lib/python3.9/site-
packages/sklearn/preprocessing/_encoders.py:975: FutureWarning: `sparse` was
renamed to `sparse_output` in version 1.2 and will be removed in 1.4.
`sparse_output` is ignored unless you leave `sparse` to its default value.
  warnings.warn(
```

```
[22]: df.head()
```

```
[22]:  Размер ссуды, руб  Срок ссуды, мес  Среднемесячный доход, руб  \
0          10000          12          4500
1          14000          12          8500
2          25000          18          7000
3          64000          48          7000
4           3500           6          3000

    Среднемесячный расход, руб  Наличие недвижимости  Наличие автотранспорта  \
0                3000                1                1
1                3000                1                1
2                4000                1                1
3                5000                1                1
4                1500                0                1
```

	Наличие банковского счета	Наличие страховки \
0	0	0
1	0	0
2	0	0
3	0	0
4	0	0

	Срок работы на данном предприятии, лет \
0	6
1	10
2	8
3	9
4	7

	Срок работы на данном направлении, лет ... \
0	8 ...
1	12 ...
2	8 ...
3	11 ...
4	8 ...

	Направление деятельности заемщика_Адм.-хоз. и транспортная службы \
0	0.0
1	1.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Бухгалтерия, финансы и планирование \
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Вспомогательный технический персонал \
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Кадровая служба и секретариат \
0	0.0
1	0.0
2	0.0

3	0.0
4	0.0

	Направление деятельности заемщика_Пр.-техн. обесп. и телекоммуникации \
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Реклама и маркетинг \
0	1.0
1	0.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Служба безопасности \
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Снабжение и сбыт \
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

	Направление деятельности заемщика_Участие в основной деятельности \
0	0.0
1	0.0
2	1.0
3	1.0
4	1.0

	Направление деятельности заемщика_Юридическая служба
0	0.0
1	0.0
2	0.0
3	0.0
4	0.0

[5 rows x 72 columns]

```
[23]: df.to_csv('CreditSampleNormalize.csv', index=False, encoding='utf-8')
```

3 Сравнение доли каждого из классов

```
[24]: for class_type in df.columns:  
       print(df[class_type].value_counts(normalize=True), end='\n\n')
```

Размер ссуды, руб

13500	0.046980
14000	0.040268
4000	0.033557
16500	0.033557
39000	0.033557

...

41000	0.006711
4500	0.006711
7000	0.006711
51500	0.006711
14500	0.006711

Name: proportion, Length: 73, dtype: float64

Срок ссуды, мес

12	0.395973
6	0.275168
18	0.221477
24	0.060403
30	0.020134
42	0.013423
48	0.006711
36	0.006711

Name: proportion, dtype: float64

Среднемесячный доход, руб

6000	0.073826
9000	0.067114
7000	0.067114
11000	0.067114
13000	0.053691
9500	0.053691
7500	0.046980
8000	0.046980
5500	0.046980
11500	0.040268
8500	0.040268
12500	0.040268
6500	0.033557
10500	0.026846
3500	0.026846

4000	0.020134
13500	0.020134
15000	0.020134
4500	0.020134
15500	0.020134
2500	0.020134
14000	0.013423
16000	0.013423
16500	0.013423
3000	0.013423
5000	0.013423
10000	0.013423
22500	0.006711
17500	0.006711
18000	0.006711
2000	0.006711
14500	0.006711
20000	0.006711
20500	0.006711
27000	0.006711
17000	0.006711
18500	0.006711

Name: proportion, dtype: float64

Среднемесячный расход, руб

4000	0.114094
3000	0.100671
3500	0.080537
5000	0.080537
4500	0.073826
2000	0.073826
5500	0.067114
2500	0.053691
6000	0.053691
6500	0.046980
8500	0.040268
7000	0.040268
7500	0.033557
8000	0.033557
9500	0.020134
1500	0.020134
9000	0.020134
11000	0.013423
14500	0.006711
10000	0.006711
11500	0.006711
13500	0.006711
1000	0.006711

Name: proportion, dtype: float64

Наличие недвижимости

1 0.805369

0 0.194631

Name: proportion, dtype: float64

Наличие автотранспорта

1 0.550336

0 0.449664

Name: proportion, dtype: float64

Наличие банковского счета

0 0.805369

1 0.194631

Name: proportion, dtype: float64

Наличие страховки

0 0.899329

1 0.100671

Name: proportion, dtype: float64

Срок работы на данном предприятии, лет

6 0.154362

3 0.154362

4 0.134228

5 0.134228

8 0.107383

2 0.107383

7 0.060403

9 0.046980

10 0.033557

12 0.026846

14 0.020134

11 0.020134

Name: proportion, dtype: float64

Срок работы на данном направлении, лет

8 0.161074

5 0.154362

7 0.140940

6 0.114094

4 0.087248

11 0.073826

9 0.067114

3 0.060403

10 0.046980

12 0.026846

```
13    0.020134
15    0.013423
2     0.013423
14    0.013423
16    0.006711
Name: proportion, dtype: float64
```

```
Пол
1     0.563758
0     0.436242
Name: proportion, dtype: float64
```

```
Семейное положение
1     0.630872
0     0.369128
Name: proportion, dtype: float64
```

Количество лет

```
26    0.093960
22    0.060403
25    0.046980
19    0.046980
27    0.040268
45    0.040268
23    0.040268
24    0.040268
29    0.040268
35    0.033557
20    0.033557
37    0.033557
21    0.033557
33    0.026846
30    0.026846
50    0.026846
41    0.026846
28    0.020134
48    0.020134
36    0.020134
53    0.020134
46    0.020134
62    0.020134
34    0.020134
42    0.013423
70    0.013423
39    0.013423
51    0.013423
44    0.013423
57    0.013423
```

32	0.013423
43	0.006711
60	0.006711
31	0.006711
66	0.006711
63	0.006711
40	0.006711
64	0.006711
54	0.006711
47	0.006711
69	0.006711
38	0.006711

Name: proportion, dtype: float64

Количество иждивенцев

1	0.315436
0	0.275168
3	0.228188
2	0.181208

Name: proportion, dtype: float64

Срок проживания в данной местности, лет

15	0.087248
13	0.073826
22	0.060403
21	0.060403
18	0.053691
14	0.053691
11	0.046980
12	0.046980
19	0.046980
10	0.046980
16	0.040268
17	0.040268
24	0.033557
8	0.033557
25	0.026846
23	0.020134
26	0.020134
31	0.020134
9	0.020134
34	0.020134
6	0.013423
20	0.013423
5	0.013423
30	0.013423
4	0.013423
33	0.013423

7 0.013423
32 0.013423
37 0.006711
40 0.006711
28 0.006711
36 0.006711
29 0.006711
44 0.006711
Name: proportion, dtype: float64

Обеспеченность займа
1 0.966443
0 0.033557
Name: proportion, dtype: float64

Давать кредит
1 0.765101
0 0.234899
Name: proportion, dtype: float64

Цель ссуды_Иное
0.0 0.90604
1.0 0.09396
Name: proportion, dtype: float64

Цель ссуды_Оплата за образование
0.0 0.805369
1.0 0.194631
Name: proportion, dtype: float64

Цель ссуды_Оплата услуг (мед., юрид. и т.п.)
0.0 0.90604
1.0 0.09396
Name: proportion, dtype: float64

Цель ссуды_Покупка и ремонт недвижимости
0.0 0.798658
1.0 0.201342
Name: proportion, dtype: float64

Цель ссуды_Покупка товара
0.0 0.610738
1.0 0.389262
Name: proportion, dtype: float64

Цель ссуды_Турпоездки, развлечения и т.п.
0.0 0.973154
1.0 0.026846

Name: proportion, dtype: float64

Основное направление расходов_Выплаты по исполнительным документам

0.0 0.993289

1.0 0.006711

Name: proportion, dtype: float64

Основное направление расходов_Выплаты по кредитам/займам

0.0 0.973154

1.0 0.026846

Name: proportion, dtype: float64

Основное направление расходов_Затраты на образование (в т.ч. детей)

0.0 0.872483

1.0 0.127517

Name: proportion, dtype: float64

Основное направление расходов_Иное

0.0 0.986577

1.0 0.013423

Name: proportion, dtype: float64

Основное направление расходов_Мобильная связь, Интернет

0.0 0.966443

1.0 0.033557

Name: proportion, dtype: float64

Основное направление расходов_Одежда, продукты питания и т.п.

0.0 0.771812

1.0 0.228188

Name: proportion, dtype: float64

Основное направление расходов_Оплата услуг (мед., юрид. и т.п.)

0.0 0.932886

1.0 0.067114

Name: proportion, dtype: float64

Основное направление расходов_Покупка и ремонт недвижимости

0.0 0.912752

1.0 0.087248

Name: proportion, dtype: float64

Основное направление расходов_Покупка товаров длит. пользования

0.0 0.812081

1.0 0.187919

Name: proportion, dtype: float64

Основное направление расходов_Помощь родственникам

0.0 0.973154
1.0 0.026846
Name: proportion, dtype: float64

Основное направление расходов_Содержание/аренда недвижимости, а/т
0.0 0.90604
1.0 0.09396
Name: proportion, dtype: float64

Основное направление расходов_Турпоездки, развлечения и т.п.
0.0 0.899329
1.0 0.100671
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Вооруженные силы
0.0 0.986577
1.0 0.013423
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Здравоохранение (гос.)
0.0 0.986577
1.0 0.013423
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Здравоохранение (комерч.)
0.0 0.993289
1.0 0.006711
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Издательская деятельность
0.0 0.993289
1.0 0.006711
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Иное
0.0 0.973154
1.0 0.026846
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Информатика и телекоммуникации
0.0 0.932886
1.0 0.067114
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Коммунальное хо-во / Сфера услуг
0.0 0.986577
1.0 0.013423
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Легкая и пищевая промышленность
0.0 0.966443
1.0 0.033557
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Машиностроение и металлообработка
0.0 0.926174
1.0 0.073826
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Наука и культура
0.0 0.939597
1.0 0.060403
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Образование (гос.)
0.0 0.973154
1.0 0.026846
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Образование (комерч.)
0.0 0.966443
1.0 0.033557
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Ощественное питание
0.0 0.919463
1.0 0.080537
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Правоохранительные органы
0.0 0.986577
1.0 0.013423
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Реклама, PR-Агенства, СМИ
0.0 0.993289
1.0 0.006711
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Салоны красоты и здоровья
0.0 0.973154
1.0 0.026846
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Сборочные производства
0.0 0.946309

1.0 0.053691
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Сельское хозяйство
0.0 0.973154
1.0 0.026846
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Торговля оптовая, поср. деятельность
0.0 0.932886
1.0 0.067114
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Торговля розничная
0.0 0.973154
1.0 0.026846
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Транспорт и связь
0.0 0.959732
1.0 0.040268
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Туризм
0.0 0.966443
1.0 0.033557
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Увесилительный, игровой и шой-бизнес
0.0 0.926174
1.0 0.073826
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Федеральное и муниципальное управление
0.0 0.959732
1.0 0.040268
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Финансы, банковское дело
0.0 0.926174
1.0 0.073826
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Химия, парфюмерия, фармацевтика
0.0 0.95302
1.0 0.04698
Name: proportion, dtype: float64

Отраслевая принадлежность предприятия_Юридические и нотариальные услуги

0.0 0.986577

1.0 0.013423

Name: proportion, dtype: float64

Направление деятельности заемщика_Адм.-хоз. и транспортная службы

0.0 0.939597

1.0 0.060403

Name: proportion, dtype: float64

Направление деятельности заемщика_Бухгалтерия, финансы и планирование

0.0 0.926174

1.0 0.073826

Name: proportion, dtype: float64

Направление деятельности заемщика_Вспомогательный технический персонал

0.0 0.939597

1.0 0.060403

Name: proportion, dtype: float64

Направление деятельности заемщика_Кадровая служба и секретариат

0.0 0.973154

1.0 0.026846

Name: proportion, dtype: float64

Направление деятельности заемщика_Пр.-техн. обесп. и телекоммуникации

0.0 0.966443

1.0 0.033557

Name: proportion, dtype: float64

Направление деятельности заемщика_Реклама и маркетинг

0.0 0.959732

1.0 0.040268

Name: proportion, dtype: float64

Направление деятельности заемщика_Служба безопасности

0.0 0.939597

1.0 0.060403

Name: proportion, dtype: float64

Направление деятельности заемщика_Снабжение и сбыт

0.0 0.932886

1.0 0.067114

Name: proportion, dtype: float64

Направление деятельности заемщика_Участие в основной деятельности

1.0 0.557047

0.0 0.442953

Name: proportion, dtype: float64

Направление деятельности заемщика_Юридическая служба

0.0 0.979866

1.0 0.020134

Name: proportion, dtype: float64

4 Разбиение выборки на обучающую и тестовую

```
[25]: X = df.drop('Давать кредит', axis=1)
      y = df['Давать кредит']

      X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.30,
      ↪random_state=42)
```

```
[26]: (X_train.shape, X_test.shape, y_train.shape, y_test.shape)
```

```
[26]: ((104, 71), (45, 71), (104,), (45,))
```

5 Построение классификатора, реализующего метод дерева решений

Описание задания: Постройте классификатор, реализующий метод дерева решений. В качестве критерия разбиения возьмите критерий информативности. Реализуйте оба способа оценки информативности (индекс Джинни и энтропию Шеннона – выбор через гиперпараметр классификатора).

5.1 Классификатор с критерием информативности Джинни

```
[27]: clf_gini = DecisionTreeClassifier(criterion='gini', random_state=42)
      clf_gini.fit(X_train, y_train)

      gini_predictions = clf_gini.predict(X_test)
      gini_accuracy = accuracy_score(y_test, gini_predictions)
      gini_report = classification_report(y_test, gini_predictions)

      print(f'Точность: {gini_accuracy}')
      print(gini_report)
```

Точность: 0.6222222222222222

	precision	recall	f1-score	support
0	0.20	0.18	0.19	11
1	0.74	0.76	0.75	34
accuracy			0.62	45
macro avg	0.47	0.47	0.47	45
weighted avg	0.61	0.62	0.62	45

Анализ результатов классификатора с критерием информативности Джинни Общая точность модели составляет 62.22%. Модель демонстрирует значительно более высокую точность (precision), полноту (recall) и F1-балл в предсказании класса “Дали кредит” (1) по сравнению с классом “Не дали кредит” (0), что указывает на её лучшую способность корректно идентифицировать случаи выдачи кредита.

5.2 Классификатор с энтропией Шеннона.

```
[28]: clf_entropy = DecisionTreeClassifier(criterion='entropy', random_state=42)
      clf_entropy.fit(X_train, y_train)

      entropy_predictions = clf_entropy.predict(X_test)
      entropy_accuracy = accuracy_score(y_test, entropy_predictions)
      entropy_report = classification_report(y_test, entropy_predictions)

      print(f'Точность: {entropy_accuracy}')
      print(entropy_report)
```

Точность: 0.7777777777777778

	precision	recall	f1-score	support
0	0.60	0.27	0.37	11
1	0.80	0.94	0.86	34
accuracy			0.78	45
macro avg	0.70	0.61	0.62	45
weighted avg	0.75	0.78	0.75	45

Анализ результатов классификатора с энтропией Шеннона. В сравнении с первым анализом, где использовался критерий Джинни, модель дерева решений с критерием энтропии Шеннона показала значительно лучшие результаты.

Общая точность модели увеличилась с 62.22% до 77.78%, что свидетельствует о более высокой эффективности в классификации. Особенно заметно улучшение в точности и полноте предсказания для класса “Дали кредит” (1), а также уменьшение разрыва в производительности между классами “Дали кредит” и “Не дали кредит”. Это указывает на более сбалансированную и точную классификацию при использовании энтропии Шеннона.

5.3 6. Обучение с использованием гиперпараметров

```
[29]: criteria = ['gini', 'entropy']
      max_depths = [3, 5, 7, None]
      min_samples_leaf = [1, 5, 10]

      results = []

      for criterion in criteria:
          for max_depth in max_depths:
```

```

for min_sample_leaf in min_samples_leaf:
    model = DecisionTreeClassifier(criterion=criterion,
                                  max_depth=max_depth,
                                  min_samples_leaf=min_sample_leaf,
                                  random_state=42)

    model.fit(X_train, y_train)
    y_pred = model.predict(X_test)
    accuracy = accuracy_score(y_test, y_pred)
    results.append({"Criterion": criterion, 'Max Depth': max_depth, 'Min_
↪Samples Leaf': min_sample_leaf, 'Accuracy': accuracy})

sorted_results = sorted(results, key=lambda x: x['Accuracy'], reverse=True)
results_refined = pd.DataFrame(sorted_results)
results_refined.head(10)

```

```

[29]:
 Criterion  Max Depth  Min Samples Leaf  Accuracy
0         gini         5.0              10  0.800000
1         gini         7.0              10  0.800000
2         gini        NaN              10  0.800000
3      entropy         5.0              10  0.800000
4      entropy         7.0              10  0.800000
5      entropy        NaN              10  0.800000
6         gini         5.0               5  0.777778
7      entropy         5.0               5  0.777778
8      entropy        NaN               1  0.777778
9         gini         3.0               5  0.755556

```

Анализ результатов моделей дерева решений с различными гиперпараметрами
Максимальная точность 80% достигается при использовании как индекса Джинни, так и энтропии Шеннона, при этом наилучшие результаты наблюдаются при максимальной глубине дерева 5-7 и минимальном количестве объектов в листе от 1 до 5. Эти данные свидетельствуют о высокой эффективности деревьев решений для классификации в данном наборе данных, демонстрируя хорошее разделение классов и устойчивость к переобучению.

6 Дополнительно

Найдите возможность визуализации дерева решений (функция `export_graphviz` из `graphviz` в комплекте с `pydotplus`). Реализуйте визуализацию одного из вариантов полученных деревьев.

```

[30]: from sklearn.tree import plot_tree
import matplotlib.pyplot as plt

plt.figure(figsize=(20,10))
plot_tree(clf_entropy, filled=True, rounded=True, class_names=True,
↪feature_names=X_train.columns)
plt.show()

```

